

Análisis de Datos I – Tarea 6

Pedro D. Llerenas
pedro.llerenas@cimat.mx

2025-10-27

1. Pregunta de gráficas.

En mi opinión, la mejor es la de la NASA, ya que no solo es la más simple de seguir, el mensaje que desea transmitir es claro: el aumento en temperatura es significativo. Las demás me parecen más difíciles de analizar (por complejidad) y entender qué es lo que quieren que la audiencia reciba.

2. Verificar que para cualquier par de v.a. X, Y :

$$\mathbf{Var}(X + Y) = \mathbf{Var}(X) + \mathbf{Var}(Y) + 2\mathbf{Cov}(X, Y). \quad (1)$$

Proof. Recordemos que la definición de covarianza es la siguiente:

$$\mathbf{Cov}(X, Y) := \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \quad (2)$$

Entonces, obtenemos las siguientes igualdades:

$$\mathbf{Var}(X + Y) = \mathbb{E}[(X + Y)^2] - \mathbb{E}[X + Y]^2 \quad (3)$$

$$= \mathbb{E}[X^2 + 2XY + Y^2] - (\mathbb{E}[X] + \mathbb{E}[Y])^2 \quad (4)$$

$$= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] - (\mathbb{E}[X]^2 + 2\mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[Y]^2) \quad (5)$$

$$= (\mathbb{E}[X^2] - \mathbb{E}[X]^2) + (\mathbb{E}[Y^2] - \mathbb{E}[Y]^2) + 2(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]) \quad (6)$$

$$= \mathbf{Var}(X) + \mathbf{Var}(Y) + 2\mathbf{Cov}(X, Y). \quad (7)$$

Equation 4 se sigue de la linealidad del valor esperado. $\square$

3. Si $Y = aX + \varepsilon$, X, ε v.a. independientes con promedio 0 y $\mathbf{Var}(X) = 1$: verifique que

$$\mathbf{Cov}(X, Y) = a, \quad \mathbf{Cor}(X, Y) = \frac{a}{\sqrt{a^2 + \mathbf{Var}(\varepsilon)}}$$

Dibuja un conjunto de datos con $|\mathbf{Cov}(X, Y)|$ chico y $|\mathbf{Cor}(X, Y)|$ grande.

Proof. Recordemos que la definición de correlación es la siguiente:

$$\mathbf{Cor}(X, Y) = \frac{\mathbf{Cov}(X, Y)}{\sqrt{\mathbf{Var}(X)\mathbf{Var}(Y)}}.$$

También tenemos la siguiente propiedad de la covarianza (sabiendo que es un producto interno, no es necesario demostrar lo siguiente):

$$\mathbf{Cov}(aX + c, bY + d) = ab\mathbf{Cov}(X, Y) \quad \forall a, b, c, d \in \mathbb{R}.$$

Además, si V, W, Z son v.a., tenemos

$$\begin{aligned} \mathbf{Cov}(Z, V + W) &= \mathbb{E}[Z(V + W)] - \mathbb{E}[Z]\mathbb{E}[V + W] \\ &= \mathbb{E}[ZV] + \mathbb{E}[ZW] - \mathbb{E}[Z]\mathbb{E}[V] - \mathbb{E}[Z]\mathbb{E}[W] \\ &= \mathbf{Cov}(Z, V) + \mathbf{Cov}(Z, W). \end{aligned}$$

Entonces, con $Y = aX + \varepsilon$ y $\text{Var}(X) = 1$, tenemos

$$\begin{aligned}\text{Cov}(X, aX + \varepsilon) &= \text{Cov}(X, aX) + \text{Cov}(X, \varepsilon) \\ &= a\text{Cov}(X, X) + 0 \\ &= a\text{Var}(X) = a.\end{aligned}$$

Entonces, tenemos que

$$\begin{aligned}\text{Cor}(X, Y) &= \text{Cor}(X, aX + \varepsilon) \\ &= \frac{\text{Cov}(X, aX + \varepsilon)}{\sqrt{\text{Var}(X)\text{Var}(aX + \varepsilon)}} \\ &= \frac{a}{\sqrt{1 \cdot (a^2\text{Var}(X) + \text{Var}(\varepsilon))}} \\ &= \frac{a}{\sqrt{a^2 \cdot 1 + \text{Var}(\varepsilon)}} \\ &= \frac{a}{\sqrt{a^2 + \text{Var}(\varepsilon)}}.\end{aligned}$$

□

4. Si $X = Z + V$, $Y = Z + W$, Z, V, W v.a. independientes con promedio 0 y V, W varianza 1:

$$\text{Cor}(X, Y) = \frac{\text{Var}(Z)}{\text{Var}(Z) + 1}.$$

Proof. Como observamos en el ejercicio anterior, y usando que son independientes, observamos que

$$\begin{aligned}\text{Cov}(Z + V, Z + W) &= \text{Cov}(Z, Z) + \text{Cov}(Z, W) + \text{Cov}(V, Z) + \text{Cov}(V, W) \\ &= \text{Var}(Z) + 0 + 0 + 0 \\ &= \text{Var}(Z).\end{aligned}$$

por lo que tenemos, recordando que $\text{Var}(W) = \text{Var}(V) = 1$,

$$\begin{aligned}\text{Cor}(X, Y) &= \text{Cor}(Z + V, Z + W) \\ &= \frac{\text{Cov}(Z + V, Z + W)}{\sqrt{\text{Var}(Z + V)\text{Var}(Z + W)}} \\ &= \frac{\text{Var}(Z)}{\sqrt{(\text{Var}(Z) + \text{Var}(V))(\text{Var}(Z) + \text{Var}(W))}} \\ &= \frac{\text{Var}(Z)}{\sqrt{(\text{Var}(Z) + 1)(\text{Var}(Z) + 1)}} \\ &= \frac{\text{Var}(Z)}{\text{Var}(Z) + 1}.\end{aligned}$$

□

5.

- a) Una manera para medir dependencia entre dos v.a. X y Y es *medir* la distancia entre la distribución conjunta y el producto de las marginales (que corresponde a la distribución bajo independencia). Aunque no cumple con todas las propiedades que debe cumplir una de distancia, se usa mucho la divergencia de Kullback Leibler (KL). Para el caso de dos distribuciones discretas, se define como:

$$KL(P|Q) = - \sum_x p(x) \log \frac{q(x)}{p(x)} = -\mathbb{E}_p \left[\log \frac{q(X)}{p(X)} \right]$$

Observa que $KL(P|P) = 0$. Verifica que $KL(P|Q) \geq 0$.

- b) Verifica que $I(X, Y) = KL(P(X, Y) | P(X)P(Y))$.

Proof of a. Por definición,

$$\begin{aligned} KL(P|P) &= -\mathbb{E}_p \left[\log \frac{p(X)}{p(X)} \right] \\ &= -\mathbb{E}_p [\log 1] \\ &= -\mathbb{E}_p [0] \\ &= 0. \end{aligned}$$

Por otro lado, por definición y la desigualdad de Jensen (sabiendo que $\log$ es convexa),

$$\begin{aligned} KL(P|Q) &= - \sum_x p(x) \log \frac{q(x)}{p(x)} \\ &\geq - \log \sum_x p(x) \frac{q(x)}{p(x)} \quad (\text{Jensen}) \\ &= - \log \sum_x q(x) \\ &= - \log 1 \\ &= 0. \end{aligned}$$

□

Proof of b. Por definición y ley de probabilidad total,

$$\begin{aligned} I(X, Y) &= H(Y) - H_X(Y) \\ &= \sum_x \sum_y P(X=x)P(Y=y|X=x) \log P(Y=y|X=x) - \sum_y P(Y=y) \log P(Y=y) \\ &= \sum_x \sum_y P(X=x, Y=y) \log P(Y=y|X=x) - \sum_y \sum_x P(X=x, Y=y) \log P(Y=y) \\ &= \sum_{x,y} P(X=x, Y=y) \log P(Y=y|X=x) - P(X=x, Y=y) \log P(Y=y) \\ &= \sum_{x,y} P(X=x, Y=y) \log \frac{P(Y=y|X=x)}{P(Y=y)} \\ &= \sum_{x,y} P(X=x, Y=y) \log \frac{P(X=x, Y=y)}{P(X=x)P(Y=y)} \end{aligned}$$

$$\begin{aligned}
 &= - \sum_{x,y} P(X=x, Y=y) \log \frac{P(X=x)P(Y=y)}{P(X=x, Y=y)} \\
 &= KL(P(X, Y) \mid P(X)P(Y)).
 \end{aligned}$$

Con esto, es claro que

$$I(X, Y) = KL(P(X, Y) \mid P(X)P(Y)) = KL(P(Y, X) \mid P(Y)P(X)) = I(Y, X).$$

□

6. Un robot viaja de posición p_1 a p_2 , de p_2 a p_3 , y de p_3 a p_4 . El tiempo para viajar de p_i a p_{i+1} es $\mathcal{N}(i, i)$ horas. Calcula la probabilidad que el viaje dure más de 6 horas si sabes que tardó menos de 1 hora para viajar de p_1 a p_2 .

Sea T_i el tiempo que se tarda de p_i a p_{i+1} , entonces el tiempo total $T = T_1 + T_2 + T_3$. Como son variables independientes, su suma es nuevamente una distribución normal, con $T \sim \mathcal{N}(1 + 2 + 3, 1 + 2 + 3) = \mathcal{N}(6, 6)$. Como sabemos que $T_1 < 1$, nuestro problema se reduce a calcular la probabilidad condicional $P(T > 6 \mid T_1 < 1)$. Ahora, notemos que como $T_2 + T_3$ es independiente de T_1 , por lo que podemos reemplazarlo de la siguiente manera:

$$P(T_2 + T_3 > 6 - T_1 \mid T_1 < 1) = P(T_2 + T_3 > 6 - 1) = P(T_2 + T_3 > 5).$$

Ahora, como $T_2 + T_3 \sim \mathcal{N}(5, 5)$, la normalizamos:

$$Z = \frac{T_2 + T_3 - 5}{\sqrt{5}} \sim \mathcal{N}(0, 1).$$

Ahora, tenemos

$$\begin{aligned}
 P(T_2 + T_3 > 5) &= P(\sqrt{5}Z + 5 > 5) \\
 &= P(Z > 0) \\
 &= 0.5.
 \end{aligned}$$

7. En este ejercicio simulamos muestras de distribución multivariadas Gaussianas y buscamos visualizaciones informativas. Las tienes que generar a partir de muestras de estándar normales usando la propiedad que si

$$X = \mathbb{A}Y + \mu \quad \text{con } Y = (Y_1, \dots, Y_d) \text{ y } \{Y_i\} \sim \mathcal{N}(0, 1) \text{ independientes}$$

entonces $X \sim \mathcal{N}(\mu, \mathbb{A}\mathbb{A}^T)$.

Simula muestras de $X = (X_1, \dots, X_4) \sim \mathcal{N}(\mu, \mathbb{C})$ y busca visualizaciones informativas que vimos en clase para diferentes elecciones de $\mathbb{C}$.




Figure 1: Pair plot de las 4 variables




Figure 2: Ejes horizontales, no se distingue nada (normalmente distribuida)




Figure 3: En 3d, con y_4 como el color (ver plt.html)




Figure 4: En 3d, con y_4 como el color (ver plt.html)




Figure 5: En 3d, con y_4 como el color (ver plt.html)