

Análisis de Datos I – Tarea 8

Pedro D. Llerenas
pedro.llerenas@cimat.mx

2025-11-19

1. Para investigar si una moneda es justa o no, alguien decide que va a lanzar la moneda 100 veces. Si el número de veces de obtener sol es entre 42% y 58%, va a apoyar la hipótesis de que la moneda es justa. Calcula la probabilidad de un error tipo I correspondiente.

Un error de tipo I se obtiene al rechazar la hipótesis nula cuando es verdadera. Entonces, supongamos que, efectivamente, si X es la v.a. del resultado de tirar una moneda es $X \sim \text{Bern}(0.5)$, y al lanzarla 100 veces, es decir, $Y \sim \text{Binomial}(100, 0.5)$. Tenemos 2 casos:

- $Y \leq 42$
- $Y \geq 58$

Es decir, queremos $1 - P(42 < Y < 58) = P(Y \leq 42) + P(Y \geq 58)$. Notemos que como la moneda es justa, $P(Y \leq 42) = P(Y \geq 58)$ (por simetría alrededor de $Y = 50$), por lo que solo calculamos uno de ellos. Obtenemos

$$P(Y \leq 42) = \sum_{i=0}^{42} \binom{100}{i} 0.5^i (0.5)^{100-i} \quad (1)$$

$$= \sum_{i=0}^{42} \binom{100}{i} 0.5^{100} \quad (2)$$

$$\approx 0.0666. \quad (3)$$

Concluimos que un error de tipo I ocurre con probabilidad

$$2P(Y \leq 42) = 0.133. \quad (4)$$

□

2. ¿Cierto, falso o indecible? Explica tu respuesta.

- a) En pruebas de hipótesis con el enfoque de Neyman-Pearson $\alpha + \text{poder} = 1$.
- b) Al aumentar α , en general la curva de poder va a subir.
- c) Si el tamaño de la muestra disminuye, la probabilidad de un error de tipo II va a aumentar.

a) Falso. Definimos $\alpha = P_{H_0}$ (error tipo I) y poder = $1 - P_{H_1}$ (error tipo II). Entonces,

$$\alpha + \text{poder} = 1 + P_{H_0} - P_{H_1}. \quad (5)$$

Entonces, el enunciado solo se cumple cuando los errores son iguales.

- b) Cierto. Cuando aumentamos α , rechazamos H_0 con datos menos extremos, aun cuando H_0 es verdadero. Esto implica que también rechazamos H_0 con datos menos extremos cuando H_1 es verdadero. Es decir, $1 - P_{H_1}$ es mayor, ya que reducimos el error de tipo II.
- c) Cierto. Sabemos que el poder es inversamente proporcional a $\frac{\sigma}{\sqrt{n}}$ (donde el numerador de la expresión completa es la diferencia de las medias, como vimos en clase). Es decir, proporcional a $\frac{\sqrt{n}}{\sigma}$. Entonces, si decrece n , el poder decrece, y por lo tanto, el error de tipo II incrementa.




Figure 1: Curvas que indican el poder (área a la izquierda de la línea α bajo H_1) y el error de tipo I (área bajo H_0 hacia la izquierda de α).

3. Supongamos que se tienen muestras de dos v.a. X y Y . Se hace la prueba de hipótesis:

$$H_0 : \mathbb{E}[X] - \mathbb{E}[Y] = 0 \quad \text{vs.} \quad H_1 : \mathbb{E}[X] - \mathbb{E}[Y] \neq 0. \quad (6)$$

Se obtiene un valor p igual a 0.002. Este valor indica:

- a) Tenemos evidencia de una gran diferencia entre los promedios de X y Y .
- b) Tenemos evidencia fuerte de una diferencia entre los promedios de X y Y .
- c) Observamos una diferencia grande en el promedio muestral de X y Y .
- d) Todo lo anterior.
- e) Nada de lo anterior.

Elige la respuesta correcta y motiva tu elección.

- b) El p -valor diminuto nos dice que los datos observados no soportan la hipótesis nula, pero no nos dice nada de las magnitudes de lo que comparamos, solamente si es plausible o no.

4. Durante los juegos olímpicos de Salt Lake City surgió en un periódico la discusión si en las pruebas de 1500m de patinaje, la persona en el carril exterior no tendría ventaja sobre el carril interior. Se organizaron 24 pruebas (una se cancelo por caída). Abajo los tiempos. Aplica una(s) pruebas de estadística relevante para contestar esta pregunta.

Race number	Inner lane	Outer lane	Difference	Race number	Inner lane	Outer lane	Difference
1	107.04	105.98	1.06	2	109.24	108.20	1.04
3	111.02	108.40	2.62	4	108.02	108.58	-0.56
5	107.83	105.51	2.32	6	109.50	112.01	-2.51
7	111.81	112.87	-1.06	8	111.02	106.40	4.62
9	106.04	104.57	1.47	10	110.15	110.70	-0.55
11	109.42	109.45	-0.03	12	108.13	109.57	-1.44
14	105.86	105.97	-0.11	15	108.27	105.63	2.64
16	107.63	105.41	2.22	17	107.72	110.26	-2.54
18	106.38	105.82	0.56	19	107.78	106.29	1.49
20	108.57	107.26	1.31	21	106.99	103.95	3.04
22	107.21	106.00	1.21	23	105.34	105.26	0.08
24	108.76	106.75	2.01				

Sea H_0 que los signos de las diferencias de tiempos son aleatorios. Usaremos el test 70 de Wilcoxon-Mann-Whitney. Esto hace énfasis en los signos de las diferencias, y sumamos los índices donde se presenten los signos con menor frecuencia.

Race	Sign
1	+
2	+
3	+
4	—
5	+
6	—
7	—
8	+
9	+
10	—
11	—
12	—
14	—
15	+
16	+
17	—
18	+
19	+
20	+
21	+
22	+
23	+
24	+

Esto nos da un total de 15 signos positivos y 8 signos negativos. Entonces, sumamos los índices donde se encuentran los signo negativos:

$$R = 4 + 6 + 7 + 10 + 11 + 12 + 14 + 17 = 81 \quad (7)$$

Calculamos

$$R' = 8 * (23 + 1) - 81 = 111. \quad (8)$$

Entonces, usamos R para el test, ya que es el menor. Con la significancia $\alpha = 0.05$ de un lado (solo queremos saber si el de fuera tiene ventaja), el valor crítico según la tabla 21 es 65, por lo que **no** rechazamos la hipótesis nula. Es decir, los datos no indican que haya relevancia en la elección de carril.

5. En un estudio sobre herencia genética de Margolin [1988], se tomaron muestras de diferentes grupos étnicos. Tomaron muestras de sangre de cada individuo de diferentes grupos étnicos. Tomaron muestras de sangre de cada individuo y se midieron varias sustancias. Nos limitamos a los grupos Americano nativo y Caucasiano y la variable MSCE (mean sister chromatid exchange). Los datos obtenidos son:

Americano nativo	8.50	9.48	8.65	8.16	8.83	7.76	8.63	—	—
Caucasiano	8.27	8.20	8.25	8.14	9.00	8.10	7.20	8.32	7.70

Usa una prueba no para métrica para la hipótesis de que los conjuntos de datos provienen de una misma distribución. Compara tu resultado con los que se obtienen con una prueba computacionalmente intensiva.

Hint: para permutar valores; por ejemplo en R se obtiene una permutación de 1, 2, ..., 9, 10 con el comando `sample(1:10, 10)`, o sea, muestra sin reemplazo. En Python puedes usar `numpy.random.permutation`.

Definimos nuestras hipótesis como

$$H_0 : \text{misma distribución}, \quad H_1 : \text{diferente distribución.} \quad (9)$$

Usaremos la *Wilcoxon inversion test* o *U-test* (test 49). Asumimos que ambas distribuciones son continuas y que las muestras son aleatorias e independientes. Juntando y ordenando los datos, tenemos la siguiente lista:

7.20 7.70 7.76 8.10 8.14 8.16 8.20 8.25 8.27 8.32 8.50 8.63 8.65 8.83 9.00 9.48

Tenemos $2 + 4 + 5 + 5 + 5 + 6 + 7 = 34$ inversiones. El número de no-inversiones es $9 \cdot 7 - 34 = 29$. Para $\alpha = 0.05$, el valor crítico es 15, por lo que **no** rechazamos la hipótesis nula.

Haciéndolo computacionalmente, usamos el código en `cauc.py`. Esto nos genera los siguientes resultados:

```
> sample median diff: 0.43
> permutation p-value: 0.088
```


Es decir, **no** rechazamos la hipótesis nula. Esto refuerza el test anterior.

6. Sea c una cierta cadena binaria de longitud 100. Se quiere verificar si proviene de una muestra $\text{Bern}(0.5) =: H_0$. Para eso se calcula el número de cambios (T_1) y la longitud de la cadena más larga de un mismo valor (T_2). Un cambio es un 1 seguido por un 0, o un 0 seguido por un 1 en la cadena.

Usando muchas simulaciones de cadenas bajo H_0 , estima y visualiza la distribución de $T = (T_1, T_2)$.

Pide un conocido generar una cadena binaria lanzando 100 veces una moneda y otra cadena que se inventa (fake). Aplica lo anterior para distinguir cual de los dos es fake basado en el valor de p .

Obtenemos la siguiente gráfica al hacer 1000 experimentos de cadenas de 100 bits. (ver `bernoulli.py`)



Ahora, dada una cadena de bits de 100 dígitos, si queremos adivinar si fue generada aleatoriamente (es decir, que cada bit fue generado independientemente con una distribución de Bernoulli), verificamos los números T_1 y T_2 y vemos su probabilidad según la distribución dada.

Supongamos que nos proporcionan la siguiente cadena de longitud 100:

```
1001001010
1010101010
0010101001
0001000011
1110100101
0010101010
1100100100
1010010011
1101010101
0101111111
```

Esto nos da el par $(68, 7)$. Este valor se encuentra fuera de los valores generados, por lo que tiene probabilidad 0 (en nuestra muestra).

Ahora, le pedimos a nuestro amigo (🤖) que lance una moneda 100 veces. Obtiene la siguiente secuencia:

```
0110111010
0101101100
1000111110
0101101111
0001011000
1010010000
1111110010
0101010110
1010100101
0110100011
```

Esto nos da el par $(56, 7)$, que calculando su frecuencia en las cadenas generadas, tiene probabilidad 0.001. Es decir, es probable que nuestro amigo haya hecho trampa al generar la cadena. La siguiente gráfica muestra donde se ubican los puntos de las cadenas probadas (rojo y azul).

